

**IMPLEMENTASI *GRAPH-BASED CLUSTERING* PADA APLIKASI WEBSITE
UNTUK PENGELOMPOKAN DOKUMEN TUGAS PERKULIAHAN
MAHASISWA BERDASARKAN KEMIRIPAN SUBSTANSI**

*Implementation Of Graph-Based Clustering In Website Application For Clustering
Student Course Assignments Based On Substance Similarity*

PROPOSAL TUGAS AKHIR

Proposal ini disusun untuk memenuhi salah satu syarat menyelesaikan Pendidikan
Program Diploma 3 Program Studi Teknik Informatika di
Jurusan Teknik Komputer dan Informatika

Oleh:

Dhea Dria Spralia	231511040
Berliana Novianti	231511072
Jihan Humaira	231511079



**PROGRAM DIPLOMA TIGA
PROGRAM STUDI TEKNIK INFORMATIKA
JURUSAN TEKNIK KOMPUTER DAN INFORMATIKA
POLITEKNIK NEGERI BANDUNG**

2026

BIODATA PENULIS



Nama Dhea Dria Spralia

NIM 231511040

Tempat, Tanggal Lahir : Cimahi, 07 April 2004
SD & Tahun Lulus : SDN Karang Mekar Mandiri 1 dan Tahun 2017
SMP & Tahun Lulus : SMP Negeri 6 Cimahi dan Tahun 2020
SMA & Tahun Lulus : SMA Negeri 5 Cimahi dan Tahun 2023
Prestasi yang pernah dicapai : -



Nama : Berliana Novianti

NIM : 231511072

Tempat, Tanggal Lahir : Bandung, 21 November 2005
SD & Tahun Lulus : SDN Sukamenak 02 dan Tahun 2017
SMP & Tahun Lulus : MTs. Persis 60 Katapang dan Tahun 2020
SMA & Tahun Lulus : SMAN 1 Margahayu dan Tahun 2023
Prestasi yang pernah dicapai : -



Nama : Jihan Humaira

NIM : 231511079

Tempat, Tanggal Lahir : Bandung, 26 Desember 2004
SD & Tahun Lulus : SDN 062 Ciujung Bandung dan Tahun 2017
SMP & Tahun Lulus : SMPN 14 Bandung dan Tahun 2020
SMA & Tahun Lulus : SMA Sumatra 40 Bandung dan Tahun 2023
Prestasi yang pernah dicapai : -

DAFTAR ISI

DAFTAR ISI.....	i
DAFTAR GAMBAR	iii
DAFTAR TABEL	iv
DAFTAR RUMUS	v
DAFTAR ISTILAH	vi
DAFTAR SINGKATAN	ix
BAB I PENDAHULUAN	1
I.1 Latar Belakang	1
I.2 Rumusan Masalah	3
I.3 Tujuan Pengembangan	3
I.4 Pemangku Kepentingan dan Manfaat Hasil Pengembangan Web	4
I.5 Dukungan Data.....	5
I.6 Ruang Lingkup & Batasan	5
I.7 Sistematika Penulisan.....	8
BAB II TINJAUAN PUSTAKA.....	9
II.1 Dasar Teori.....	9
II.1.1 Karakteristik Dokumen Esai Akademik.....	9
II.1.2 <i>Preprocessing</i> Teks.....	10
II.1.3 <i>Sentence-BERT</i> (SBERT).....	11
II.1.4 <i>Cosine Similarity</i>	11
II.1.5 Pendekatan <i>Graph-Based Clustering</i>	12
II.1.6 Konsep Parafrasa dan Ambang Batas Kemiripan	13
II.1.7 Throwaway Prototyping.....	14
II.1.8 Waterfall.....	15
II.2 Karya Ilmiah Sejenis	16
BAB III METODOLOGI PELAKSANAAN	18
III.1 Penjelasan Pengembangan	18

III.2	Data Pengembangan.....	18
III.3	Objek Pengembangan.....	19
III.4	Perangkat Pendukung.....	19
III.5	Tahapan Pelaksanaan Pengembangan.....	21
III.5.1	Identifikasi Masalah	22
III.5.2	Studi Literatur	22
III.5.3	Requirement Definition.....	22
III.5.4	System and Software Design	23
III.5.5	Implementation and Unit Testing.....	24
III.5.6	Integration and System Testing.....	25
III.6	Rancangan Jadwal Pelaksanaan Tugas Akhir	25
III.7	Perencanaan Biaya	26
DAFTAR PUSTAKA		28

DAFTAR GAMBAR

Gambar II. 1 Ilustrasi Graph-Based Clustering.....	13
Gambar II. 2 Throwaway (Sumber: Repository UMN BAB II Landasan Teori) .	15
Gambar II. 3 Waterfall (Sumber: Sommerville (2016))	16
Gambar III. 1 SDLC Throwaway Prototyping dan waterfall.....	21

DAFTAR TABEL

Tabel II. 1 Karya Ilmiah Sejenis	16
Tabel III. 1 Perangkat Pendukung.....	20
Tabel III. 2 Rancangan Jadwal Pelaksanaan	25
Tabel III. 3 Perencanaan Biaya	27

DAFTAR RUMUS

Rumus II.2. 1 Rumus <i>Cosine Similarity</i>	12
--	----

DAFTAR ISTILAH

<i>Backend</i>	Bagian dari arsitektur aplikasi yang berjalan di sisi server untuk menangani logika program, pemrosesan data, dan koneksi basis data (menggunakan Python/Flask)
<i>Blackbox Testing</i>	Metode pengujian perangkat lunak yang berfokus pada fungsionalitas input dan output aplikasi tanpa melihat struktur kode internalnya.
<i>Connected Component</i>	Sub-graf utuh yang terbentuk dari simpul yang saling terhubung, secara ekuivalen direpresentasikan sebagai satu kluster tugas mahasiswa yang terindikasi memiliki kesamaan substansi.
<i>Contextual Embedding</i>	Representasi teks dalam bentuk vektor yang mampu menangkap makna kata berdasarkan konteks kalimat sekitarnya, bukan hanya arti kata secara mandiri.
<i>Cross-Encoder</i>	Arsitektur model yang memproses pasangan dokumen secara bersamaan; memiliki akurasi tinggi namun kompleksitas komputasinya sangat berat.
<i>Dataset</i>	Kumpulan data mentah (dalam penelitian ini berupa file PDF tugas) yang diorganisir untuk keperluan analisis atau pengujian sistem.
<i>Edge (Sisi)</i>	Garis penghubung antar simpul dalam graf yang mewakili hubungan atau bobot nilai kemiripan antar dokumen.
<i>Frontend</i>	Bagian antarmuka aplikasi yang berinteraksi langsung dengan pengguna (<i>user interface</i>), meliputi desain visual dan elemen interaktif pada halaman web.

<i>Grading Fairness</i>	Prinsip keadilan dan konsistensi dalam memberikan penilaian terhadap tugas mahasiswa tanpa dipengaruhi oleh bias urutan pemeriksaan atau kelelahan pemeriksa.
<i>Many-to-Many</i> (banyak-ke-banyak)	Jenis relasi dalam basis data di mana satu data dalam tabel A dapat dihubungkan dengan beberapa data dalam tabel B, dan sebaliknya, satu data dalam tabel B juga dapat dihubungkan dengan beberapa data dalam tabel A.
<i>NetworkX</i>	Pustaka (<i>library</i>) pada bahasa pemrograman Python yang digunakan untuk pembuatan, manipulasi, dan analisis struktur graf kompleks.
<i>NLP (Natural Language Processing)</i>	Bidang kecerdasan buatan yang berfokus pada interaksi antara komputer dan bahasa manusia untuk memahami atau menghasilkan teks.
<i>Node (Simpul)</i>	Representasi entitas (dalam hal ini dokumen tugas mahasiswa) di dalam struktur jaringan graf.
<i>OCR (Optical Character Recognition)</i>	Teknologi untuk mengubah gambar teks (seperti hasil scan atau foto) menjadi teks digital yang dapat diedit. (Teknologi ini menjadi batasan masalah/tidak digunakan dalam sistem ini.
<i>Outlier</i>	Data yang memiliki karakteristik sangat unik sehingga nilai kemiripannya berada di bawah <i>threshold</i> dan tidak dapat dikelompokkan ke kluster manapun.
<i>Parafrasa</i>	Teknik pengungkapan kembali suatu gagasan atau kalimat dengan susunan kata yang berbeda namun tetap memiliki makna yang sama (sering digunakan mahasiswa dalam mengerjakan tugas).

Parameter	Nilai penentu yang diatur untuk mengontrol jalannya algoritma; dalam penelitian ini merujuk pada nilai <i>threshold</i> kemiripan.
<i>Pra-trained Model</i>	Model kecerdasan buatan yang telah dilatih sebelumnya menggunakan dataset besar oleh pihak ketiga dan siap digunakan untuk tugas spesifik.
<i>Siamese Networks (Bi-encoder)</i>	Arsitektur modifikasi pada SBERT yang memproses dokumen menjadi representasi vektor secara independen.
<i>SDLC (Software Development Life Cycle)</i>	Kerangka kerja sistematis yang mendefinisikan tahapan-tahapan dalam proses pengembangan perangkat lunak.
<i>Transformer</i>	Arsitektur model <i>neural network</i> modern yang mendasari model bahasa seperti BERT dalam memahami konteks kalimat secara utuh.
<i>Threshold (Ambang Batas)</i>	Nilai parameter penentu yang ditetapkan oleh sistem untuk menyaring data, seperti persentase batas minimum untuk mengelompokkan dokumen tugas yang terindikasi mirip.
<i>Unsupervised Learning</i>	Paradigma pembelajaran mesin di mana sistem mencari pola atau kelompok dalam data secara mandiri tanpa memerlukan label atau kunci jawaban.
<i>Unit testing</i>	Tahap pengujian untuk memvalidasi apakah unit atau komponen terkecil dari kode program sudah berfungsi dengan benar secara terisolasi.
<i>Variabel</i>	Komponen data yang nilainya bersifat dinamis atau berubah-ubah; dalam penelitian ini merujuk pada isi dokumen tugas yang diinputkan.

DAFTAR SINGKATAN

Singkatan	Nama Singkatan	Pemakaian pertama kali pada halaman
POLBAN	Politeknik Negeri Bandung	1
NLP	Natural Language Processing	1
PDF	Portable Document Format	1
BERT	<i>Bidirectional Encoder Representations from Transformers</i>	2
SBERT	<i>Sentence-BERT</i>	2
JTK	<i>Jurusan Teknik Komputer dan Informatika</i>	4
OCR	<i>Optical Character Recognition</i>	6
URL	<i>Uniform Resource Locator</i>	8
VS Code	<i>Visual Studio Code</i>	18
IDE	<i>Integrated Development Environment</i>	18
SDLC	<i>System Development Life Cycle</i>	19
DFD	<i>Data Flow Diagram</i>	22
ERD	<i>Entitiy Relationship Diagram</i>	22
DFD	<i>Data Flow Diagram</i>	22
UI/UX	<i>User Interface/User Experience</i>	22
RAB	Rencana Anggaran Biaya	23

BAB I

PENDAHULUAN

Bab ini menguraikan landasan permasalahan dalam pengembangan aplikasi pengelompokan dokumen tugas mahasiswa berdasarkan tingkat kemiripan substansi. Pembahasan difokuskan pada isu efisiensi waktu komputasi manual di lingkungan Jurusan Teknik Komputer dan Informatika POLBAN serta urgensi penerapan sistem otomatisasi. Selain itu, bab ini juga menjabarkan rumusan masalah, batasan masalah, tujuan dan manfaat tugas akhir, serta sistematika penulisan laporan.

I.1 Latar Belakang

Dalam pelaksanaan tugas mata kuliah di Jurusan Teknik Komputer dan Informatika POLBAN sering kali menggunakan instrumen penugasan teks, khususnya yang berbentuk esai akademik (deskriptif maupun argumentatif) berformat .pdf. Pemeriksaan dan komparasi dokumen penugasan esai ini sebagian besar masih dilakukan secara manual. Studi kasus di lingkungan politeknik (Amalia et al., 2021) menunjukkan evaluasi dokumen teks secara manual memiliki beban waktu komputasi yang tinggi bagi pengajar. Secara kuantitatif, pemrosesan satu berkas teks secara manual memerlukan waktu 7 hingga 10 menit (Mariyani et al., 2022). Untuk satu kelas berisi 30 mahasiswa, proses komparasi sekuensial memakan waktu komputasi hingga 5 jam per penugasan. Akumulasi jumlah kelas paralel membuat metode komparasi manual ini tidak scalable.

Ketidakseimbangan rasio antara jumlah pengajar dan tingginya volume dokumen tugas menjadi konstrain utama dalam kapasitas pemrosesan evaluasi akademik. Keterbatasan komputasi manual dalam memproses data teks berskala masif secara sekuensial menghasilkan inkonsistensi pada pemetaan kemiripan antardokumen. Tantangan ini semakin diperberat oleh tren peningkatan angka kecurangan akademik berupa plagiarisme di lingkungan pendidikan tinggi. Berdasarkan studi komparasi (Prakoso et al., 2024), terbukti terjadi lonjakan tingkat

kemiripan dokumen tugas mahasiswa secara signifikan dari tahun ke tahun, di mana tingkat kemiripan maksimal melonjak drastis dari angka 45% pada tahun 2021 menjadi 64% pada tahun 2022. Praktik kecurangan ini umumnya dilakukan dengan cara menyalin substansi jawaban tugas rekan sejawat atau sumber lain, yang kemudian dimanipulasi agar terlihat orisinal (Mastiah and Tirsa, 2025). Disamping itu, esai akademik pada tingkat pendidikan tinggi umumnya memiliki struktur argumen yang kompleks dan rentan terhadap teknik parafrasa tersebut. Metode komputasi berbasis pencocokan kata kunci (*keyword matching*) tidak dapat mengidentifikasi kemiripan substansi pada kalimat yang telah dimodifikasi (parafrasa). Implementasi *Natural Language Processing* (NLP) terbukti mengotomatisasi komparasi teks dengan output terstandarisasi dan waktu inferensi yang lebih cepat (Sihombing, 2022).

Arsitektur *Transformer* seperti BERT memiliki metrik pemetaan semantik yang akurat (Syah et al., 2025). Namun, arsitektur *Cross-Encoder* pada BERT standar memproses dokumen secara berpasangan (*pair-wise comparisons*), sehingga menghasilkan kompleksitas komputasi eksponensial pada data berskala besar (Zhang et al., 2022). Oleh karena itu, tugas akhir ini menerapkan *Sentence-BERT* (SBERT) dengan modifikasi *Siamese Networks* (*Bi-encoder*). SBERT mengekstraksi teks dari dokumen .pdf menjadi representasi vektor secara independen. Vektor tersebut kemudian dihitung nilai kemiripannya menggunakan algoritma *Cosine Similarity* untuk mereduksi waktu inferensi (Park and Shin, 2023).

Meskipun kombinasi SBERT dan *Cosine Similarity* mampu mengkalkulasi persentase kemiripan antardokumen secara akurat, output yang dihasilkan hanyalah berupa matriks persentase numerik. Jika dihadapkan pada skala data yang masif, pengajar tetap harus memetakan hubungan duplikasi tersebut secara manual. Oleh karena itu, diperlukan algoritma clustering untuk mengotomatisasi pengelompokan dokumen-dokumen bersubstansi serupa agar mudah dievaluasi. Dalam pengelompokan dokumen tugas, jumlah kelompok (*cluster*) tidak diketahui di awal. Algoritma berbasis sentroid yang memerlukan inisialisasi jumlah klaster, seperti K-Means, tidak dapat digunakan. Tugas akhir ini menerapkan *Graph-Based*

Clustering dengan merepresentasikan dokumen sebagai simpul (*node*) dan nilai *Cosine Similarity* sebagai bobot sisi (*edge weight*). Dokumen dengan nilai kemiripan di atas ambang batas (*threshold*) akan terhubung membentuk *subgraph* (*connected components*) secara dinamis.

Berdasarkan parameter tersebut, tugas akhir ini mengusulkan pembangunan aplikasi web untuk mendeteksi kemiripan dan mengelompokkan dokumen tugas mahasiswa berformat .pdf secara otomatis. Integrasi ekstraksi teks, SBERT, *Cosine Similarity*, dan *Graph-Based Clustering* ini bertujuan untuk memangkas waktu pemeriksaan dokumen secara signifikan serta memberikan output berupa klaster tugas yang saling terhubung secara semantik. Dengan demikian, aplikasi ini diharapkan dapat menjadi alat bantu pendukung yang mengefisienkan proses evaluasi tugas bervolume tinggi di lingkungan akademik, tanpa mengambil alih otoritas penilaian (*scoring*) terhadap kebenaran substansi tugas mahasiswa.

I.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, maka rumusan masalah dalam tugas akhir ini adalah sebagai berikut:

1. Dibutuhkan solusi untuk mengotomatisasi proses deteksi kemiripan teks pada dokumen tugas berformat .pdf guna mengatasi inefisiensi waktu komputasi pemrosesan manual.
2. Dibutuhkan solusi untuk memetakan skor kemiripan antardokumen menggunakan algoritma *Graph-Based Clustering* agar dapat membentuk kelompok (klaster) jawaban secara dinamis, tanpa perlu inisialisasi jumlah kelompok di awal.

I.3 Tujuan Pengembangan

Berdasarkan perumusan masalah yang telah diuraikan sebelumnya, tujuan utama dari pembangunan aplikasi ini adalah sebagai berikut:

1. Membangun aplikasi yang mengotomatisasi komputasi deteksi kemiripan dokumen tugas berformat .pdf dalam satu folder guna mereduksi waktu

pemeriksaan manual, di mana tingkat efisiensi waktu tersebut diukur dan divalidasi berdasarkan penerimaan pengguna akhir (*User Acceptance*).

2. Mengimplementasikan ekstraksi model SBERT dan metrik *Cosine Similarity* yang dipetakan ke dalam algoritma *Graph-Based Clustering* untuk menghasilkan pengelompokan tugas secara otomatis.

I.4 Pemangku Kepentingan dan Manfaat Hasil Pengembangan Web

Adapun manfaat yang diharapkan dapat diperoleh dari hasil pengembangan dan implementasi aplikasi ini, baik dari sisi keilmuan maupun operasional, adalah sebagai berikut:

1. Bagi Bidang Keilmuan
 - a. Memberikan wawasan keilmuan baru dalam domain *Natural Language Processing* (NLP), khususnya mengenai implementasi algoritma representasi vektor (SBERT) dan *Graph-Based Clustering* untuk memproses serta mengomparasi kumpulan dokumen berformat .pdf dalam satu direktori secara otomatis. Memperkaya literatur terkait pemanfaatan teknologi komputasi pada evaluasi pendidikan, di mana algoritma deteksi kemiripan ditransformasikan dari sekadar instrumen pendeteksi kemiripan menjadi model pengelompokan jawaban untuk mendukung standarisasi penilaian.
2. Bagi Pengajar (Dosen)
 - a. Mengeliminasi konstrain inefisiensi waktu dan keterbatasan kapasitas pemrosesan manual, sehingga waktu komputasi evaluasi yang dihemat dapat dialokasikan secara lebih efisien untuk analisis substansi akademik.
 - b. Membantu dosen memetakan mahasiswa yang memiliki indikasi jawaban serupa secara cepat melalui klaster, sehingga proses evaluasi tidak perlu lagi dilakukan dengan membandingkan puluhan dokumen satu per satu secara sekuensial.
3. Bagi Mahasiswa
 - a. Memberikan transparansi bahwa deteksi kemiripan tugas dilakukan secara sistematis oleh algoritma komputasi (berdasarkan kemiripan makna dan

parafrasa), yang memberikan hasil pemetaan dokumen yang lebih persisten dibandingkan asumsi manual.

I.5 Dukungan Data

Data yang digunakan untuk mendukung proses pengembangan dan pengujian sistem pada Tugas Akhir ini bersumber dari instansi internal, yaitu Jurusan Teknik Komputer dan Informatika (JTK), Politeknik Negeri Bandung.

Secara umum, data pendukung yang dibutuhkan berupa sampel dokumen nyata hasil penugasan mahasiswa dari beberapa mata kuliah di lingkungan JTK. Mengingat fokus Tugas Akhir adalah pengelompokan berdasarkan kemiripan substansi teks, pemilihan sampel data didasarkan pada kriteria dokumen yang memiliki karakteristik naratif-deskriptif atau argumentatif. Kriteria utama data yang digunakan adalah dokumen yang didominasi oleh narasi teks bahasa alami (*natural language text*), seperti esai, ringkasan literatur, atau laporan analisis yang minim akan unsur non-tekstual (seperti kode program atau notasi matematis kompleks). Kumpulan data (dataset) ini diperoleh secara langsung melalui dosen pengampu mata kuliah terkait yang bersedia memberikan sampel berkas tugas mahasiswanya dari semester berjalan maupun semester sebelumnya. Keseluruhan data tersebut berupa berkas dokumen digital berformat PDF (*Portable Document Format*).

Mengingat data yang digunakan adalah dokumen akademik internal mahasiswa, data ini bersifat tertutup (*private dataset*) dan tidak bersumber dari tautan *open-source* di internet. Seluruh sampel dokumen yang dikumpulkan akan digunakan secara eksklusif untuk keperluan pengujian akurasi ekstraksi teks, simulasi deteksi kemiripan menggunakan model *Sentence-BERT* (SBERT), dan pengujian keberhasilan fitur pengelompokan (*clustering*) pada sistem yang dikembangkan.

I.6 Ruang Lingkup & Batasan

Agar aplikasi yang dikembangkan berfokus pada tujuan utama dan tidak melenceng dari sasaran yang diinginkan. Adapun ruang lingkup yang dibuat, yaitu:

1. Aplikasi dikembangkan dalam bentuk berbasis *website* untuk memudahkan akses dosen tanpa instalasi.
2. Data yang diproses merupakan dokumen penugasan berbasis narasi teks bahasa alami (*natural language text*) berupa esai akademik berjenis deskriptif atau argumentatif berbahasa Indonesia yang lazim digunakan pada evaluasi pembelajaran tingkat perguruan tinggi, dalam bentuk berkas digital berformat .pdf yang diunggah secara serentak (*multi-file upload*) untuk satu kelas penugasan.
3. Aplikasi ditujukan untuk digunakan oleh Dosen Pengampu mata kuliah di Jurusan Teknik Komputer dan Informatika sebagai alat bantu pemeriksaan tugas.
4. Sistem menerapkan metode *Sentence-BERT* (SBERT) yang dikombinasikan dengan algoritma *Cosine Similarity*. Hal ini memungkinkan sistem mendeteksi kemiripan berdasarkan konteks kalimat dan makna semantik (*contextual embedding*) secara utuh, sehingga lebih akurat dalam mengenali substansi jawaban yang serupa meskipun menggunakan struktur kalimat yang berbeda (*parafrase*).

Adapun batasan masalah yang menetapkan parameter dan pagar dalam pembuatan sistem ini adalah sebagai berikut:

1. Sistem hanya menerima masukan berkas dengan ekstensi .pdf. Format lain (seperti .doc lawas, .rtf, .pages, dan lain-lain) tidak dicakup dalam sistem ini.
2. Sistem hanya memproses berkas berbasis teks (*text-based/selectable*). Sistem tidak menangani dokumen hasil pemindaian gambar (*scanned image*) atau tulisan tangan yang difoto, karena memerlukan teknologi OCR (*Optical Character Recognition*) yang berada di luar lingkup tugas akhir ini.
3. Sistem dioptimalkan untuk memproses kalimat bahasa manusia (Natural Language). Sistem tidak dirancang untuk memproses dan menganalisis tingkat kemiripan pada dokumen tugas yang didominasi oleh elemen teknis, seperti bahasa pemrograman (source code), notasi/rumus matematis kompleks, data tabular, serta grafik.

4. Implementasi *Sentence-BERT* menggunakan *Word Embedding Model* yang mendukung Bahasa Indonesia. Tugas Akhir ini berfokus pada penerapan model tersebut untuk klasterisasi tugas, bukan pada pelatihan model bahasa baru dari nol.
5. Pengecekan kemiripan dilakukan secara lokal (internal), yaitu membandingkan satu berkas tugas mahasiswa dengan tugas mahasiswa lain dalam satu folder/angkatan yang sama. Sistem tidak melakukan pengecekan terhadap sumber eksternal (*internet/website*) atau *database* jurnal *online*.
6. Sistem mengimplementasikan metode Unsupervised Learning berbasis komparasi matriks silang (Many-to-Many). Sistem murni membandingkan dokumen antar-mahasiswa untuk mencari indikasi kesamaan substansi, dan tidak membandingkan jawaban mahasiswa dengan kunci jawaban dari dosen (One-to-Many).
7. Sistem tidak memiliki kapabilitas untuk menilai kebenaran atau memberikan skor akhir (*scoring*) pada tugas mahasiswa. Dokumen yang tidak memiliki tingkat kemiripan dengan siapa pun (berada di bawah ambang batas) akan diidentifikasi sebagai *Outlier* atau "Dokumen Unik (Aman dari Duplikasi)".
8. Sistem hanya melakukan pengelompokan berdasarkan persentase kemiripan dan tidak memiliki kapabilitas untuk menilai kebenaran substansi atau memberikan skor akhir (*scoring*) secara otomatis. Dokumen yang berada di bawah ambang batas kemiripan akan diidentifikasi sebagai *outlier* (dokumen unik). Keputusan akhir mengenai apakah *outlier* tersebut merupakan jawaban yang sangat brilian atau justru jawaban yang salah/melenceng, serta pemberian nilai pada setiap klaster, dikembalikan sepenuhnya kepada otoritas dosen pengampu.
9. Tolak ukur keberhasilan pemangkasan waktu komputasi (efisiensi) dinilai berdasarkan evaluasi subjektif dan kesepakatan dari pengguna akhir (dosen) melalui pengujian UAT (*User Acceptance Testing*).

I.7 Sistematika Penulisan

Sistematika dalam penulisan Proposal Tugas Akhir ini dibagi menjadi tiga bab dengan penjelasan sebagai berikut:

- BAB I** Bab ini berisi gambaran umum mengenai pengembangan yang dilakukan, termasuk latar belakang yang menjelaskan permasalahan utama dan urgensi pengembangan, rumusan masalah yang mendefinisikan ruang lingkup permasalahan, tujuan dan manfaat dari hasil pengembangan, ruang lingkup pengembangan, serta sistematika penulisan laporan.
- BAB II** Bab ini membahas kajian literatur yang berkaitan dengan pengembangan yang dilakukan. Termasuk dalam tinjauan pustaka adalah studi terhadap karya ilmiah atau produk sejenis, serta dasar teori yang mendukung perancangan dan implementasi pengembangan yang dilakukan.
- BAB III** Bab ini menjelaskan pendekatan yang digunakan dalam proses pengembangan. Pembahasan dalam bab ini mencakup jenis dan metode pengembangan yang digunakan, tahapan pengembangan, data yang digunakan, objek pengembangan, perangkat pendukung yang digunakan, prosedur pengembangan yang diterapkan dalam laporan ini, serta rencana pada penjadwalan dan perencanaan biaya anggaran tugas akhir.

BAB II

TINJAUAN PUSTAKA

Bab ini menguraikan landasan teori dan kajian literatur yang menjadi acuan utama dalam pengembangan sistem. Pembahasan dimulai dengan tinjauan terhadap karya ilmiah sejenis sebagai pembandingan, dilanjutkan dengan penjelasan konsep-konsep teoritis yang mendasari solusi teknis, teknik *Preprocessing* Teks, metode *Sentence-BERT* (SBERT), algoritma *Cosine Similarity*, serta konsep *Document Clustering*.

II.1 Dasar Teori

Bab ini akan membahas dasar-dasar teori yang relevan dan mendukung dalam menyelesaikan permasalahan yang muncul selama proses pengembangan perangkat lunak.

II.1.1 Dokumen Esai Akademik

Dokumen esai akademik merupakan instrumen penugasan terstruktur di lingkungan perguruan tinggi yang dirancang untuk mengukur tingkat pemahaman, daya analisis, dan keterampilan komunikasi tertulis mahasiswa secara ilmiah. Berdasarkan pendekatan pemaparan gagasannya, dokumen tugas esai pada tingkat pendidikan tinggi umumnya diklasifikasikan ke dalam beberapa jenis, di mana dua jenis esai yang paling sering diujikan adalah esai deskriptif dan esai argumentatif (Kurniasih et al., 2024).

1. Esai Deskriptif

Esai deskriptif merupakan jenis dokumen akademik yang bertujuan untuk memberikan gambaran, penjelasan, atau rincian spesifik mengenai suatu objek, konsep, atau peristiwa secara objektif (Kurniasih et al., 2024). Penugasan esai deskriptif menuntut mahasiswa untuk membedah komponen-komponen dari suatu topik sedetail mungkin, sehingga pembaca dapat memahami struktur esensial dari topik yang dibahas tanpa adanya sisipan opini dari penulisnya.

2. Esai Argumentatif

Berbeda dengan pemaparan objektif pada esai deskriptif, esai argumentatif adalah jenis dokumen penugasan yang menuntut mahasiswa untuk mengambil sikap atau posisi (pro maupun kontra) terhadap suatu isu sentral. Tujuan utama dari esai argumentatif adalah untuk meyakinkan pembaca agar menerima pandangan penulis. Oleh karena itu, struktur esai ini memiliki tingkat kompleksitas yang lebih tinggi, di mana mahasiswa tidak hanya menyajikan opini, melainkan juga harus menyusun klaim logis dan membantah argumen oposisi menggunakan pembuktian data atau rujukan literatur yang valid (Kurniasih et al., 2024).

Mengingat kedua bentuk esai akademik tersebut memiliki kekayaan makna kontekstual serta kompleksitas variasi susunan kalimat (parafrasa), komparasi kemiripan antardokumen memerlukan pendekatan analisis semantik menggunakan *Natural Language Processing* (NLP) yang mutakhir, alih-alih sekadar menggunakan pemadanan kata kunci (*keyword matching*).

II.1.2 *Preprocessing* Teks

Tahapan *preprocessing* bertujuan untuk membersihkan data teks mentah dari dokumen PDF agar terstruktur sebelum diolah oleh model bahasa. Berbeda dengan pendekatan NLP tradisional (seperti TF-IDF) yang mengharuskan penghapusan kata hubung (*Stopword Removal*) dan pemotongan imbuhan (*Stemming*), arsitektur Transformer seperti BERT justru membutuhkan struktur kalimat yang utuh untuk memahami konteks melalui *attention mechanism* (Ortakci and Borhan, 2025). Oleh karena itu, *preprocessing* pada sistem ini dibatasi pada:

1. *Case Folding*: Proses mengubah seluruh huruf menjadi huruf kecil (*lowercase*) serta menghapus karakter non-alfanumerik, tanda baca yang tidak relevan, dan tautan (URL) untuk mengurangi noise komputasi tanpa merusak struktur kalimat.
2. *Tokenizing*: Proses memecah teks bukan berdasarkan kata utuh, melainkan menggunakan algoritma *WordPiece Tokenizer* bawaan BERT, yang memotong kata menjadi sub-kata untuk menangani kosakata yang tidak dikenali (*Out-of-Vocabulary*).

II.1.3 *Sentence-BERT (SBERT)*

Sentence-BERT (SBERT) adalah modifikasi dari arsitektur jaringan BERT standar yang mengadopsi arsitektur *Siamese Networks (Bi-encoder)*. Pemilihan SBERT didasarkan pada kelemahan fundamental model BERT standar dalam menangani komparasi berskala besar. Model BERT tradisional menggunakan arsitektur *Cross-Encoder*, di mana setiap pasangan dokumen harus dimasukkan ke dalam model secara bersamaan. Menurut (Zhang et al., 2022), hal ini memicu kompleksitas waktu komputasi eksponensial yang sangat membebani kinerja sistem (*resource-heavy*). SBERT memecahkan masalah ini dengan memproses kalimat secara independen untuk menghasilkan vektor embedding berukuran tetap. Pendekatan ini secara efektif mereduksi kompleksitas komputasi menjadi linear, sehingga mampu memecahkan masalah kelambatan waktu inferensi pada arsitektur NLP sebelumnya dan memungkinkan sistem membandingkan ratusan dokumen tugas mahasiswa hanya dalam hitungan detik (Park & Shin, 2023).

II.1.4 *Cosine Similarity*

Cosine Similarity adalah algoritma untuk mengukur tingkat kemiripan antara dua dokumen dengan menghitung kosinus sudut antara dua vektor representasi dokumen tersebut. Penggunaan *Cosine Similarity* jauh lebih unggul dibandingkan metode pencocokan leksikal konvensional seperti *Jaccard Similarity* maupun algoritma *Rabin-Karp* (Putra et al., 2024). Algoritma *Jaccard* dan *Rabin-Karp* sangat rentan terhadap parafrasa, apabila mahasiswa menggunakan sinonim atau mengubah struktur kalimat (misalnya aktif menjadi pasif), metode konvensional akan menganggap dokumen tersebut berbeda secara fundamental. Sebaliknya, karena *Cosine Similarity* mengevaluasi kedekatan sudut representasi vektor bermakna semantik yang dihasilkan SBERT, sistem tetap mampu mendeteksi tingkat kesamaan substansi secara persisten terlepas dari perubahan susunan kata. Nilai kemiripan berkisar antara 0 (tidak mirip) hingga 1 (sangat mirip). Rumus dasarnya adalah:

$$\text{Cosine Similarity} = \frac{A \cdot B}{\|A\| \times \|B\|}$$

Rumus II.2. 1 Rumus *Cosine Similarity*


Dimana A dan B merepresentasikan vektor dari dua dokumen tugas yang diukur, pembilang merupakan hasil perkalian titik (*dot product*) dan penyebut merupakan perkalian panjang (*magnitude*) kedua vektor.

II.1.5 Pendekatan *Graph-Based Clustering*

Metode pengelompokan yang diterapkan dalam sistem ini adalah pendekatan berbasis graf (*Graph-Based Clustering*). Menurut (Li et al., 2023), algoritma *clustering* berbasis graf merupakan metode yang merepresentasikan data sebagai struktur jaringan dinamis yang terdiri dari simpul (*node*) dan sisi (*edge*). Keunggulan utamanya adalah kemampuan untuk membentuk kelompok secara otomatis tanpa harus menentukan jumlah kluster di awal. Mekanisme kerja pendekatan ini dalam sistem adalah sebagai berikut:

1. Representasi: Setiap dokumen dipetakan sebagai simpul (*node*), sedangkan nilai *Cosine Similarity* antar-dokumen menjadi bobot pada sisi penghubungnya (*edge*).
2. Penyaringan (*Thresholding*): Sistem menerapkan ambang batas (*threshold*) kemiripan untuk memutuskan sisi yang memiliki bobot rendah.
3. Pembentukan *Subgraph*: Simpul-simpul yang tetap saling terhubung setelah penyaringan akan membentuk *connected components*. Setiap komponen ini diidentifikasi sebagai satu *subgraph* tugas dengan kesamaan substansi kuat, sementara simpul yang tidak terhubung menandakan dokumen yang unik.

Perubahan struktur jaringan dari kondisi awal hingga membentuk beberapa *subgraph* terpisah setelah penerapan ambang batas (*threshold*) ini diilustrasikan pada Gambar II.1.



Gambar II. 1 Ilustrasi Graph-Based Clustering

Setiap *connected component* tersebut secara ekuivalen direpresentasikan sebagai satu *subgraph* tugas mahasiswa yang terindikasi memiliki kesamaan substansi kuat. Sebaliknya, simpul atau *node* yang terisolasi (kehilangan seluruh sisi penghubungnya) menandakan bahwa dokumen tersebut bersifat unik, independen, dan aman dari indikasi duplikasi. Implementasi teknis untuk eksplorasi struktur jaringan dan eksekusi algoritma *connected components* ini dilakukan menggunakan pustaka NetworkX.

II.1.6 Konsep Parafrasa dan Ambang Batas Kemiripan

Plagiarisme atau duplikasi dalam ranah akademik tidak selalu berupa penyalinan kata demi kata, melainkan sering kali dilakukan melalui teknik parafrasa tanpa mengubah makna aslinya. Dalam sistem pemrosesan bahasa alami berbasis vektor, nilai keluaran persentase kemiripan (*Cosine Similarity*) berkisar antara 0 hingga 1 (atau 0% hingga 100%). Menentukan pada angka berapa sebuah tugas mahasiswa dikategorikan sebagai plagiarisme memerlukan penetapan ambang batas (*threshold*) yang terukur secara komputasi.

Merujuk pada klasifikasi evaluasi dokumen akademik yang dipublikasikan dalam (Saputra et al., 2023), tingkat plagiarisme berdasarkan persentase kemiripan diklasifikasikan ke dalam tiga kategori utama plagiarisme ringan ($< 30\%$), plagiarisme sedang ($30\% - 70\%$), dan plagiarisme berat ($> 70\%$). Penetapan klasifikasi akademik ini bersifat universal dalam pemrosesan teks. Secara kuantitatif, implementasi algoritma *Cosine Similarity* berbasis representasi

semantik terbukti secara empiris mampu mengidentifikasi dokumen yang melampaui ambang batas tersebut. Penelitian (Putra et al., 2024) mencatat bahwa metode ini menghasilkan tingkat presisi komparasi sebesar 61,24% pada distribusi teks yang sangat bervariasi. Kemampuan tersebut diperkuat oleh temuan (Hakiki et al., 2025) yang memvalidasi bahwa model komparasi ini mampu mendeteksi duplikasi dokumen dengan akurasi mencapai 100% serta tetap stabil dalam mengenali teks yang telah dimodifikasi atau diparafrasa.


Berdasarkan landasan literatur tersebut, sistem yang dikembangkan pada tugas akhir ini menetapkan ambang batas kemiripan awal sebesar 70%. Skor kemiripan di bawah 50% diasumsikan sebagai korelasi topik yang bersifat sangat umum, sementara skor yang melampaui rentang 70% hingga 80% akan langsung diidentifikasi oleh sistem sebagai kelompok dokumen (*cluster*) yang memiliki indikasi kuat terjadinya duplikasi atau penggunaan teknik parafrasa tingkat tinggi pada tugas mahasiswa.

II.1.7 *Throwaway Prototyping*

Model *throwaway prototyping* adalah pendekatan rekayasa perangkat lunak yang berfokus pada eksplorasi dan klarifikasi kebutuhan sistem di awal proyek. Menurut (Pressman, 2010), metode ini dilakukan dengan membangun sebuah prototipe secara cepat (*quick design*) untuk mendemonstrasikan fungsionalitas dasar kepada pemangku kepentingan. Prototipe ini berfungsi secara eksklusif sebagai alat evaluasi untuk mengidentifikasi persyaratan yang masih ambigu. Setelah spesifikasi kebutuhan sistem tervalidasi dengan jelas melalui umpan balik pengguna, prototipe tersebut akan dibuang (*throwaway*), dan sistem aktual akan dikembangkan dari awal menggunakan paradigma yang lebih terstruktur seperti metode *Waterfall*.

Dalam pengembangan sistem pengelompokan dokumen tugas perkuliahan mahasiswa ini, pendekatan *throwaway prototyping* diterapkan sebagai teknik pendukung pada fase pendefinisian kebutuhan (*requirement definition*) di dalam alur utama metode *Waterfall*. Pendekatan ini secara spesifik digunakan untuk memvalidasi spesifikasi kebutuhan visual yang masih ambigu, mengingat

parameter keluaran *clustering* belum terdefinisi secara pasti bentuk penyajiannya. Pada tahap awal, sebuah prototipe antarmuka aplikasi (*mockup*) disusun untuk memvisualisasikan fitur utama, seperti mekanisme pengunggahan dokumen dan representasi hasil pengelompokan (*clustering*). Prototipe tersebut kemudian didemonstrasikan kepada pengguna sasaran (dosen) guna memvalidasi spesifikasi kebutuhan dan alur interaksi yang diharapkan. Setelah seluruh kebutuhan fungsional tervalidasi dan disepakati, rancangan prototipe tersebut difungsikan sebatas cetak biru (*blueprint*), dan tahapan pengerjaan kode program dilanjutkan secara utuh mengikuti alur sekuensial pada metode Waterfall. Ilustrasi alur kerja dari metode *throwaway prototyping* ini dapat dilihat pada Gambar II.2.




Gambar II. 2 Throwaway (Sumber: Repository UMN BAB II Landasan Teori)

II.1.8 Waterfall

Metode Waterfall merupakan model pengembangan perangkat lunak yang menggunakan pendekatan sekuensial dan sistematis. Menurut (Sommerville, 2011), pengerjaan pada model ini mengharuskan penyelesaian suatu tahapan secara utuh sebelum berlanjut ke tahapan berikutnya, di mana luaran (output) dari satu fase menjadi landasan bagi fase setelahnya. Pendekatan ini relevan diterapkan pada sistem yang memiliki spesifikasi kebutuhan stabil dan telah terdefinisi secara komprehensif sejak awal pengerjaan. Secara terstruktur, siklus hidup model Waterfall terangkum ke dalam lima fase utama, yaitu pendefinisian kebutuhan (requirement definition), perancangan sistem dan perangkat lunak (system and software design), implementasi dan pengujian satuan (Implementation and Unit Testing), integrasi dan pengujian sistem (Integration and System Testing), serta operasi dan pemeliharaan (Operation and Maintenance). Tahapan-tahapan

berurutan pada metode Waterfall tersebut diilustrasikan secara visual pada Gambar II.3.



Gambar II. 3 Waterfall (Sumber: Sommerville (2016))

II.2 Karya Ilmiah Sejenis

Berikut adalah identifikasi karya ilmiah sejenis yang menjadi rujukan dalam Tugas Akhir ini, dirangkum dalam Tabel II.1.

Tabel II. 1 Karya Ilmiah Sejenis

No	Tahun	Penulis	Judul Karya Ilmiah	Hasil
1	2025	Hakiki, I., Atqiya, F., & Suryan, A.	Implementasi Model Sentence-Bert untuk Deteksi Plagiarisme Pada Karya Tulis Ilmiah Psikologi Berbahasa Indonesia	Penelitian ini mengimplementasikan model Sentence-BERT (SBERT) dan Cosine Similarity untuk mendeteksi tingkat kemiripan makna pada karya ilmiah berbahasa Indonesia. Hasil pengujian menunjukkan bahwa model tersebut efektif mendeteksi kesamaan teks yang diparafrasa dengan akurasi 100% pada kasus duplikasi murni dan 53,3% secara keseluruhan.
2	2023	Prismadana, T. A.	Aplikasi Ruang Tugas Dengan Deteksi Kemiripan Teks Pada Dokumen Tugas Menggunakan <i>Cosine Similarity</i>	Penelitian ini merancang aplikasi ruang pengumpulan tugas mahasiswa berbasis web yang dilengkapi fitur deteksi kemiripan teks. Hasil

No	Tahun	Penulis	Judul Karya Ilmiah	Hasil
				penelitian memvalidasi bahwa penerapan algoritma Cosine Similarity efektif dalam mengidentifikasi persentase kesamaan antar-dokumen tugas, sehingga mengefisienkan proses evaluasi oleh dosen.
3	2020	Kambey, G. E. I., Sengkey, R., & Jacobus, A.	Penerapan <i>Clustering</i> pada Aplikasi Pendeteksi Kemiripan Dokumen Teks Bahasa Indonesia	Penelitian ini menerapkan metode clustering (K-Means dan DBSCAN) berbasis frekuensi kata (leksikal) sebelum melakukan proses evaluasi kemiripan dokumen. Hasil penelitian mengonfirmasi bahwa penerapan <i>clustering</i> terbukti mempercepat waktu komputasi secara signifikan, meskipun pendekatan leksikalnya memiliki keterbatasan dalam akurasi pembacaan makna utuh.

BAB III

METODOLOGI PELAKSANAAN

Pada bab ini akan dijelaskan metodologi pengerjaan pengembangan aplikasi pengelompokan dokumen tugas mahasiswa yang akan dilakukan. Pembahasan di dalamnya mencakup penjelasan pengembangan (meliputi waktu, tempat pelaksanaan, dan jenis pengembangan), data pengembangan, objek pengembangan, serta perangkat pendukung yang digunakan. Selain itu, bab ini menguraikan tahapan pengembangan aplikasi (System Development Life Cycle) menggunakan pendekatan model hibrida (Throwaway Prototyping dan Waterfall) lengkap dengan luaran yang dihasilkan di setiap tahapan. Sebagai penutup, bab ini juga memaparkan perancangan jadwal pelaksanaan Tugas Akhir, perencanaan biaya pengembangan yang dibutuhkan.

III.1 Penjelasan Pengembangan

Pengembangan aplikasi pengelompokan tugas perkuliahan mahasiswa ini dilaksanakan sebagai bagian dari pemenuhan Tugas Akhir dengan estimasi waktu pengerjaan efektif selama satu semester. Pelaksanaan pengembangan dilakukan secara mandiri dengan lokasi kegiatan yang berpusat di lingkungan kampus Politeknik Negeri Bandung (POLBAN). Adapun jenis pengembangan yang dilakukan adalah berbasis website (*web-based application*) yang memasukan penggunaan metode *Sentence-BERT* (SBERT) untuk mengekstraksi makna semantik kalimat, algoritma *Cosine Similarity* untuk menghitung jarak kemiripan antar dokumen, serta pendekatan *Graph-Based Clustering* untuk proses pengelompokan tugas perkuliahan mahasiswa tersebut.

III.2 Data Pengembangan

Data pengembangan yang digunakan sebagai masukan (input) utama sistem bersumber dari sampel N dokumen tugas mahasiswa di lingkungan Jurusan Teknik

Komputer dan Informatika. Data yang dikelola dalam pengembangan sistem ini diklasifikasikan menjadi tiga kategori, yaitu:

1. Data Berkas Digital: Merupakan data mentah berbentuk berkas dokumen berformat PDF (Portable Document Format) yang diunggah oleh pengguna.
2. Data Teks Hasil Ekstraksi: Merupakan kumpulan karakter, kata, dan kalimat yang berhasil diekstraksi dari dalam berkas PDF untuk dianalisis kemiripan semantiknya oleh sistem.
3. Data Numerik dan Struktur Graf: Merupakan data metrik berskala 0 hingga 1 hasil komputasi Cosine Similarity, yang kemudian direpresentasikan sebagai bobot graf untuk memetakan kelompok (cluster) dokumen yang mirip.

III.3 Objek Pengembangan

Objek utama dalam pengembangan tugas akhir ini adalah sistem aplikasi pengelompokan kemiripan dokumen tugas perkuliahan mahasiswa. Sistem ini dikembangkan sebagai alat bantu komputasi yang berfokus pada analisis semantik untuk mengidentifikasi kesamaan substansi makna antar-dokumen tugas, bukan sekadar pencocokan teks secara leksikal. Keluaran (output) dari objek pengembangan ini berupa visualisasi kelompok-kelompok dokumen tugas bersubstansi serupa, yang dirancang secara spesifik untuk memfasilitasi proses pemeriksaan oleh tenaga pendidik tanpa mengambil alih otoritas dan subjektivitas penilaian akademik.

III.4 Perangkat Pendukung

Berdasarkan spesifikasi perancangan sistem, pengembangan aplikasi ini membutuhkan integrasi dari berbagai perangkat lunak dan pustaka (library). Rincian mengenai nama, versi, fungsi spesifik, serta justifikasi penggunaan dari masing-masing perangkat pendukung diilustrasikan pada Tabel III.1 berikut.


Tabel III. 1 Perangkat Pendukung

No	Nama	Versi	Fungsi	Alasan Penggunaan
1	Python	3.11.8	Bahasa Pemrograman	Diterapkan sebagai bahasa pemrograman utama karena memiliki ekosistem pustaka pemrosesan bahasa alami (NLP) yang komprehensif untuk mengakomodasi eksekusi model SBERT, komputasi matematis, dan pemodelan graf.
2	Visual Studio Code	1.86.2	Integrated Development Environment (IDE)	Digunakan sebagai lingkungan pengembangan utama karena memiliki performa operasional yang ringan, serta memfasilitasi penulisan kode (<i>backend/frontend</i>), manajemen direktori, dan integrasi terminal lokal.
3	GitHub	-	Repositori dan Kontrol Versi	Diterapkan sebagai platform repositori berbasis awan (<i>cloud</i>) untuk menyimpan kode sumber, melacak riwayat perubahan (<i>commit history</i>), serta memfasilitasi proses pencadangan (<i>backup</i>) data secara berkala.
4	MySQL	8.0.36	Sistem Manajemen Basis Data Relasional	Dipilih untuk menyimpan metadata dokumen tugas mahasiswa, merekam hasil perhitungan skor kemiripan, serta menyimpan riwayat pengelompokan (<i>clustering</i>) karena keandalannya dalam mengelola data terstruktur.
5	Flask	3.0.2	Web Micro-Framework	Digunakan sebagai kerangka kerja antarmuka aplikasi (<i>backend</i>) karena karakteristiknya yang ringan, memiliki waktu respons cepat, dan tingkat fleksibilitas tinggi untuk integrasi komputasi skala menengah.
6	Scikit-learn	1.4.1	Pustaka Komputasi Algoritma	Digunakan secara spesifik untuk mengeksekusi algoritma <i>Cosine Similarity</i> guna menghitung jarak sudut antar-vektor dokumen secara presisi.
7	Sentence-Transformers	2.5.1	Pustaka Pemrosesan Model AI	Diterapkan untuk memuat model pra-latih (<i>pre-trained model</i>) SBERT yang berfungsi mengubah input teks tugas menjadi vektor numerik yang

No	Nama	Versi	Fungsi	Alasan Penggunaan
				mempertahankan makna semantik kontekstual secara utuh.
8	NetworkX	3.2.1	Pustaka Pemodelan Graf	Digunakan untuk mengeksplorasi dan menganalisis struktur jaringan, secara khusus mengeksekusi algoritma <i>Connected Components</i> dalam proses pengelompokan (<i>clustering</i>) otomatis.

III.5 Tahapan Pelaksanaan Pengembangan

Metode Pengembangan perangkat lunak yang diterapkan pada Tugas Akhir ini merupakan pendekatan hibrida yang mengombinasikan fase *Throwaway Prototyping* dengan model *Waterfall*. Fase *Throwaway Prototyping* secara spesifik diaplikasikan pada fase pendefinisian kebutuhan untuk memvalidasi fungsionalitas sistem melalui rancangan visual interaktif. Setelah spesifikasi disepakati, rancangan visual tersebut tidak digunakan sebagai kode produksi, melainkan proses dilanjutkan menggunakan alur sekuensial *Waterfall* hingga tahap peluncuran aplikasi. Alur kerja dari metode pengembangan ini diilustrasikan pada Gambar III.1.



Gambar III. 1 SDLC Throwaway Prototyping dan waterfall

Berdasarkan diagram tersebut, penjabaran dari masing-masing tahapan pengembangan diuraikan sebagai berikut:

III.5.1 Identifikasi Masalah

Tahap inisiasi dilakukan untuk memetakan kendala utama yang terjadi pada proses pemeriksaan dokumen tugas perkuliahan. Proses identifikasi difokuskan pada analisis tingkat inefisiensi waktu operasional saat melakukan proses evaluasi kemiripan dokumen tugas perkuliahan mahasiswa secara manual. Hasil dari tahapan ini berupa rumusan permasalahan yang mendasari urgensi pembangunan sistem otomatisasi pengelompokan dokumen.

III.5.2 Studi Literatur

Tahapan ini bertujuan untuk menghimpun landasan teoretis dan metodologis dari berbagai sumber literatur akademik yang relevan. Kajian difokuskan pada eksplorasi arsitektur pemodelan bahasa *Sentence*-BERT (SBERT), kalkulasi metrik Cosine Similarity, serta mekanisme *Graph-Based Clustering* menggunakan pustaka NetworkX. Hasil studi ini diakumulasikan sebagai acuan ilmiah dalam merancang algoritma inti aplikasi.

III.5.3 Requirement Definition

Tahap ini difokuskan pada ekstraksi dan analisis spesifikasi kebutuhan sistem. Mengingat sistem ini menggunakan pendekatan *unsupervised* di mana format penyajian informasi hasil pengelompokan belum diketahui pasti oleh pengajar (*end-user*), maka diterapkan teknik *Throwaway Prototyping*. Teknik ini bertujuan untuk memvalidasi kebutuhan fungsional terkait bagaimana hasil klasterisasi dipresentasikan secara visual bersama *end-user*. Proses ini meliputi empat sub-proses:

1. *Initial Requirement*: Pengumpulan spesifikasi dasar terkait fitur-fitur yang harus diakomodasi oleh aplikasi.

2. *Develop Prototyping*: Pembuatan rancangan prototipe antarmuka (*user interface*) secara cepat guna memberikan visualisasi alur interaksi sistem.
3. *Evaluated Prototyping*: Mengingat parameter visual keluaran klastering belum terdefinisi secara pasti, prototipe didemonstrasikan langsung kepada representasi pengguna (*end-user/dosen*) untuk dievaluasi. Hal ini bertujuan untuk menemukan antarmuka hasil klasterisasi yang paling mudah dipahami dan relevan. Apabila terdapat revisi (*Not Approve*), proses dikembalikan ke tahap pembuatan prototipe.
4. *Final Requirement*: Apabila prototipe disetujui (*Approve*), rancangan dan parameter visual tersebut ditetapkan sebagai dokumen spesifikasi final. Prototipe awal kemudian dibuang (*throwaway*), dan pengembangan kode program akan dibangun dari awal berdasarkan spesifikasi yang telah divalidasi tersebut.

Hasil keluaran dari tahap ini adalah dokumen spesifikasi kebutuhan perangkat lunak yang telah divalidasi sebagai acuan mutlak pengembangan, sementara prototipe awalnya dibuang (*throwaway*).

III.5.4 System and Software Design

Spesifikasi kebutuhan yang telah berstatus final kemudian diterjemahkan ke dalam bentuk *blueprint* teknis. Perancangan pada fase ini meliputi penyusunan arsitektur sistem perangkat lunak, pemodelan struktur basis data relasional, desain tata letak antarmuka, serta penyusunan diagram alur kerja (*flowchart*) untuk proses ekstraksi dan pembandingan teks dokumen. Hasil dari tahap ini berupa dokumen perancangan sistem yang mencakup arsitektur, skema basis data, dan rancangan antarmuka pengguna (*User Interface*) sebagai panduan utama proses implementasi.

Mekanisme pengelompokan dan output sistem untuk menegaskan batasan fungsionalitasnya, sistem ini dirancang murni sebagai alat bantu bagi pengajar, bukan sebagai penentu skor evaluasi. Algoritma inti pada sistem ini dirancang sebagai satu kesatuan rantai pemrosesan (*pipeline algorithmic*) yang berkesinambungan, dengan tahapan komputasi sebagai berikut:

1. Ekstraksi Vektor (SBERT): Sistem memproses teks dari setiap dokumen menjadi representasi vektor numerik yang bertindak sebagai simpul (*node*) di dalam ruang graf.
2. Perhitungan Jarak (*Cosine Similarity*): Vektor-vektor tersebut dikomparasikan secara *many-to-many*, di mana nilai *Cosine Similarity* yang dihasilkan akan langsung direpresentasikan sebagai bobot sisi (*edge weight*) yang menghubungkan antar-simpul.
3. Pemotongan Ambang Batas (*Thresholding*): Algoritma *Graph-Based Clustering* mengevaluasi matriks jaringan tersebut dan memutuskan sisi (*edge*) yang memiliki bobot kemiripan di bawah parameter ambang batas (*threshold*) yang ditentukan.
4. Pembentukan *Subgraph* (*Connected Components*): Simpul-simpul dokumen yang tetap saling terhubung setelah pemotongan akan membentuk komponen terisolasi (*Connected Components*). Komponen inilah yang didefinisikan sistem sebagai *subgraph* tugas yang saling memiliki kesamaan substansi.
5. Penyajian Output (*Clustering*): Hasil akhir klasterisasi disajikan pada antarmuka web dalam bentuk visualisasi kelompok dokumen. Keputusan evaluasi dan penilaian akhir untuk setiap kelompok tersebut dikembalikan sepenuhnya kepada otoritas dosen pengampu.

III.5.5 Implementation and Unit Testing

Tahap konstruksi di mana seluruh rancangan teknis direalisasikan ke dalam baris kode program (*source code*). Pengembangan *backend* dan *frontend* dilakukan menggunakan bahasa pemrograman Python serta kerangka kerja Flask. Bersamaan dengan proses pengkodean, dilakukan pengujian unit (*Unit Testing*) untuk memvalidasi keandalan masing-masing modul secara terisolasi. Hasil dari tahap ini berupa basis data fisik, kumpulan kode sumber aplikasi yang telah fungsional, serta laporan hasil pengujian unit (*unit test log*).

III.5.6 Integration and System Testing

Seluruh modul program yang telah melewati pengujian unit diintegrasikan menjadi satu kesatuan arsitektur aplikasi yang utuh. Sistem kemudian dievaluasi secara komprehensif menggunakan metode *Black-Box Testing*. Pengujian ini bertujuan untuk memastikan kelancaran alur fungsional sistem, mulai dari proses unggah dokumen hingga visualisasi graf pengelompokan.

Setelah sistem dipastikan berjalan lancar dan bebas dari kecacatan fungsional (bug), tahapan selanjutnya dieksekusi dengan melakukan User Acceptance Test (UAT). Pengujian UAT ini melibatkan pengguna akhir (end-user) untuk mengevaluasi dan memvalidasi secara langsung apakah fitur rekomendasi klaster dan antarmuka sistem yang dibangun telah benar-benar menjawab kebutuhan operasional evaluasi dokumen penugasan. Hasil keluaran akhir dari keseluruhan tahap ini berupa dokumen skenario pengujian (test case), dokumen persetujuan UAT yang ditandatangani pengguna, serta sistem aplikasi utuh yang telah teruji kestabilannya dan disetujui kelayakannya.

III.6 Rancangan Jadwal Pelaksanaan Tugas Akhir

Berikut adalah jadwal pelaksanaan yang sudah disusun dalam waktu per-bulan secara lengkap pada Tabel III.2.

Tabel III. 2 Rancangan Jadwal Pelaksanaan

[illegible]

No	Tahapan & Butir Pekerjaan	Bulan Februari				Bulan Maret				Bulan April				Bulan Mei				Bulan Juni			
Mg	Minggu Ke-	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4
3.3	Evaluated Prototyping																				
3.4	Final Requirement																				
4	Perancangan Sistem (System Design)																				
4.1	Perancangan Arsitektur (Flowchart/DFD)																				
4.2	Perancangan ERD Database																				
4.3	Perancangan Antarmuka (UI/UX)																				
	Seminar 2																				
5	Implementasi (Implementation)																				
5.1	Setup Environment & Library Python																				
5.2	Backend: Preprocessing & SBERT																				
5.3	Backend: Cosine Sim. & Clustering																				
5.4	Frontend: Pembuatan Website																				
5.5	Integrasi Backend dan Frontend																				
6	Pengujian (Testing)																				
6.1	Pengujian Fungsional (Blackbox)																				
6.2	Pengujian Akurasi (Cluster Valid.)																				
	Seminar 3																				
	Penyusunan Laporan Akhir & Sidang																				

III.7 Perencanaan Biaya

Sub-bab ini menguraikan estimasi anggaran biaya operasional, meliputi biaya habis pakai, perjalanan, dan keperluan lainnya, guna mendukung pengerjaan Tugas Akhir, sebagaimana dirincikan pada Tabel III.3 berikut.

Tabel III. 3 Perencanaan Biaya

No.	Jenis Keperluan	Volume	Satuan	Harga Satuan (Rp)	Total (Rp)
A.	Biaya Habis Pakai				
1.	Kertas HVS A4 (70/80 gsm)	2	Rim	50000	100000
2.	Tinta Printer (Hitam & Warna)	1	Paket	120000	120000
3.	Alat Tulis Kantor (Map, Pulpen, dll)	1	Paket	50000	50000
4.	Kuota Internet	5	Bulan	50000	250000
5.	Hosting / Domain (Opsional untuk Demo)	1	Tahun	300000	300000
	Sub Total Biaya Habis Pakai				820000
B.	Biaya Perjalanan				
1.	Transportasi	16	Kali	10000	160000
	Sub Total Biaya Perjalanan				160000
C.	Biaya Lain-lain				
1.	Penjilidan Laporan (Proposal & Akhir)	6	Eks	40000	240000
2.	Publikasi	1	Kali	300000	300000
	Sub Total Biaya Lain-lain				540000
	TOTAL ANGGARAN				1520000

DAFTAR PUSTAKA

- Amalia, E.L., Jumadi, A.J., Mashudi, I.A., Wibowo, D.W., 2021. Analisis Metode Cosine Similarity Pada Aplikasi Ujian Online Otomatis (Studi Kasus JTI POLINEMA). *Jurnal Teknologi Informasi dan Ilmu Komputer* 8, 343–348. <https://doi.org/10.25126/jtiik.2021824356>
- Hakiki, I., Atqiya, F., Suryan, A., 2025. Implementasi Model Sentence-Bert untuk Deteksi Plagiarisme Pada Karya Tulis Ilmiah Psikologi Berbahasa Indonesia. *Cerdika: Jurnal Ilmiah Indonesia* 5, 3109–3125. <https://doi.org/10.59141/cerdika.v5i12.2889>
- Kurniasih, N., Nurislsminingsih, R., Yanto, A., 2024. KETERAMPILAN MENULIS ESAI BAGI MAHASISWA. *Communnity Development Journal* 5, 2121–2125.
- Li, Y., Nguyen, J., Anastasiu, D.C., Arriaga, E.A., 2023. CosTaL: an accurate and scalable graph-based clustering algorithm for high-dimensional single-cell data analysis. *Brief. Bioinform.* 24. <https://doi.org/10.1093/bib/bbad157>
- Mariyani, U.D., Setiyaningsih, W., Agustina, R., 2022. Pengembangan Sistem Koreksi Jawaban Esai Otomatis Menggunakan Naive Bayes Dan Pengujian Menggunakan User Acceptance Test (UAT). *Rainstek Jurnal Terapan Sains dan Teknologi* 4, 61–73. <https://doi.org/10.21067/jtst.v4i1.6857>
- Mastiah, M., Tirsa, A., 2025. PELATIHAN TEKNIK PARAFRASE UNTUK MENINGKATKAN KUALITAS PENULISAN ILMIAH MAHASISWA STKIP MELAWI. *Dedikasi: Jurnal Pengabdian Kepada Masyarakat* 5, 151–157. <https://doi.org/10.46368/dpkm.v5i1.3402>
- Ortakci, Y., Borhan, B., 2025. Optimizing SBERT for long text clustering: two novel approaches with empirical insights. *Journal of Supercomputing* 81. <https://doi.org/10.1007/s11227-025-07414-4>

- Park, Y., Shin, Y., 2023. Using Multiple Monolingual Models for Efficiently Embedding Korean and English Conversational Sentences. *Applied Sciences* 13, 5771. <https://doi.org/10.3390/app13095771>
- Prakoso, A.A., Fadilah, N., Yahya Maulana, A., 2024. Analisis Tingkat Plagiarisme Terhadap Karya Ilmiah Jurnal Mahasiswa Perpustakaan dan Sains Informasi Universitas YARSI Jakarta Tahun 2021-2022 dengan Software Turnitin. *Jurnal Pustaka Ilmiah* 10, 115. <https://doi.org/10.20961/jpi.v10i1.84924>
- Pressman, R.S., 2010. *Software engineering : a practitioner's approach*, 7th ed. McGraw-Hill Higher Education.
- Putra, R., Mustika, Z., Sumema, 2024. Similarity Judul Tugas Akhir Menggunakan Metoda Cosine, Jaccard, Rabin-Karp Pada Jurusan TI. *JITSI: Jurnal Ilmiah Teknologi Sistem Informasi* 5. <https://doi.org/10.62527/jitsi.5.4.291>
- Saputra, A.K., Endra, R.Y., Ariani, F., Tanjung, T., Prakarsya, A., 2023. Implementasi Algoritma Rabin-Karp pada Pendeteksian Plagiarisme. *EXPERT: Jurnal Manajemen Sistem Informasi dan Teknologi* 13, 23. <https://doi.org/10.36448/expert.v13i1.3161>
- Sihombing, D.O., 2022. Implementasi Natural Language Processing (NLP) dan Algoritma Cosine Similarity dalam Penilaian Ujian Esai Otomatis. *Jurnal Sistem Komputer dan Informatika (JSON)* 4, 396. <https://doi.org/10.30865/json.v4i2.5374>
- Sommerville, Ian., 2011. *Software engineering*. Pearson.
- Syah, M.P., Wardani, A.P., Idhom, M., Trimono, 2025. Perbandingan Representasi Teks Tf-Idf Dan Bert Terhadap Akurasi Cosine Similarity Dalam Penilaian Otomatis Jawaban Berbasis Teks. *Data Sciences Indonesia (DSI)* 5, 47–59. <https://doi.org/10.47709/dsi.v5i1.6021>
- Zhang, Y., Liu, J., Huang, B., Chen, B., 2022. Entity Linking Method for Chinese Short Text Based on Siamese-Like Network. *Information* 13, 397. <https://doi.org/10.3390/info13080397>